Université de Reims

Analyse comparative de TF-IDF et LSA

Étude sur le sous-corpus `talk.politics.mideast`

Auteur : Ismael Madou Gagi
Formation : Master Statistique pour l'évaluation et la prévision
Encadrant : Bart Lamiroy
Lien GitHub : github.com/Ismael-madou/LSA

1er mars 2026

Table des matières

1 Introduction 2

2 Origine des données 2

3 Protocole expérimental 2

4 Explication du code 3

5 Analyse TF-IDF 4

6 Analyse Sémantique Latente 4

7 Influence du paramètre K 5

8 Interprétation des concepts latents 5

9 Comparaison des requêtes 5

10 Discussion 6

11 Conclusion 6

1 Introduction

La représentation vectorielle des documents constitue un fondement central du traitement automatique des langues et de la recherche d'information. Deux approches structurent historiquement ce domaine : la pondération TF-IDF, issue du modèle sac-de-mots, et l'Analyse Sémantique Latente (LSA), fondée sur la réduction dimensionnelle par décomposition en valeurs singulières.

L'objectif de ce travail est triple : analyser la structure mathématique de ces deux méthodes, étudier leur comportement expérimental sur des requêtes textuelles et examiner leur capacité à capturer la structure sémantique latente d'un corpus réel.

2 Origine des données

Le corpus étudié provient de la base 20 Newsgroups, référence classique en apprentissage automatique et en classification textuelle. Cette base contient environ 20 000 documents répartis en vingt catégories thématiques issues de discussions Usenet.

Dans le cadre de cette étude, nous avons restreint l'analyse au sous-corpus :

`talk.politics.mideast`

Ce choix permet d'analyser un ensemble cohérent de discussions géopolitiques centrées sur le Moyen-Orient, tout en conservant une richesse lexicale importante.

Après prétraitement, le corpus comporte 919 documents et 18 066 termes distincts, conduisant à une matrice TF-IDF :

$$X \in \mathbb{R}^{919 \times 18066}$$

3 Protocole expérimental

Le protocole expérimental vise à comparer systématiquement TF-IDF et LSA tout en analysant l'influence des paramètres de modélisation.

Le corpus, le prétraitement linguistique (normalisation, suppression de ponctuation, suppression des stopwords anglais et lemmatisation) ainsi que la métrique de similarité (cosinus) sont maintenus constants. Les paramètres étudiés concernent principalement :

— la vectorisation TF-IDF : paramètres `min_df`, `max_df`, `ngram`,

— la réduction dimensionnelle LSA : dimension latente K.

Pour chaque configuration, nous observons :

— la dimension effective du vocabulaire,

— la structure des valeurs singulières,

— les similarités maximales pour plusieurs requêtes thématiques,
— la composition du top-k retourné.

Le corpus étant mono-thématique, l'évaluation quantitative via des métriques supervisées (Precision@k, MAP) n'est pas directement applicable. L'analyse repose donc sur la cohérence sémantique des résultats et sur la stabilité du classement lors de variations paramétriques.

4 Explication du code

Le code utilisé dans ce travail suit une organisation correspondant directement au pipeline expérimental décrit précédemment. La première étape consiste à charger les documents depuis le répertoire du sous-corpus. Les fichiers texte sont parcourus récursivement, puis lus en `utf-8` lorsque cela est possible, avec un repli en `latin-1` pour éviter l'échec de lecture sur certains fichiers. Cette étape garantit que l'expérience se déroule sur un ensemble maximal de documents valides et explique le nombre final de documents effectivement chargés.

Une seconde étape applique un prétraitement configurable : passage en minuscules, suppression de ponctuation, suppression des stopwords et lemmatisation. L'objectif est de réduire la variabilité lexicale (casse, ponctuation, variantes morphologiques) afin de stabiliser le vocabulaire final et d'améliorer la qualité de la représentation TF-IDF. Ce prétraitement agit directement sur la matrice TF-IDF construite ensuite, notamment sur sa dimension et sur la distribution des poids.

La construction de TF-IDF est ensuite réalisée à l'aide de `TfidfVectorizer`. Le code permet de faire varier des paramètres clés (`min_df`, `max_df`, `ngram`) afin de mesurer l'impact sur la taille du vocabulaire et sur la structure de la matrice. Un extrait de la matrice TF-IDF est visualisé afin d'illustrer la forte sparsité de cette représentation, comme montré en Figure 1. Cette visualisation correspond à la propriété attendue du modèle sac-de-mots : la majorité des coefficients sont nuls car un document ne contient qu'une petite portion des termes du vocabulaire global.

La LSA est ensuite obtenue en appliquant une SVD tronquée via `TruncatedSVD`. Le paramètre K contrôle la dimension latente conservée. Les valeurs singulières, présentées en Figure 2, permettent d'observer la part de structure capturée par les premiers concepts. Le code produit également deux objets essentiels : la projection des documents dans l'espace latent (matrice V, Figure 3) et la projection des termes dans l'espace latent (matrice U, Figure 4). Ces visualisations sont rendues lisibles en ne conservant qu'un échantillon de documents pour V et les termes les plus influents pour U.

Enfin, pour comparer TF-IDF et LSA sur des requêtes, le code transforme la requête textuelle en vecteur TF-IDF, calcule une similarité cosinus entre la requête et l'ensemble des documents, puis projette la requête dans l'espace latent via la SVD pour calculer

une similarité LSA comparable. Les classements affichés (top-k) permettent de confronter concrètement les deux modèles sur des requêtes thématiques cohérentes avec le corpus. Les figures des concepts (Figures 5 à 9) proviennent du tri des poids terme-concept, et constituent un support direct à l'interprétation sémantique des dimensions latentes extraites.

5 Analyse TF-IDF

La pondération TF-IDF repose sur la formule :

$$TFIDF(t, d) = TF(t, d) \times IDF(t)$$

où $TF(t, d)$ mesure l'importance locale d'un terme dans un document et $IDF(t)$ pénalise les termes fréquents à l'échelle du corpus.

La matrice obtenue est fortement sparse : chaque document n'active qu'une fraction limitée du vocabulaire total. Cette sparsité entraîne une représentation en très grande dimension où la similarité cosinus reste modérée, les vecteurs étant majoritairement orthogonaux. La structure creuse de cette représentation est visible sur un extrait en Figure 1.

TF-IDF privilégie une correspondance lexicale stricte : les documents contenant explicitement les termes de la requête sont favorisés.

6 Analyse Sémantique Latente

La LSA applique une décomposition SVD :

$$X = U\Sigma V^T$$

et conserve une approximation de rang réduit :

$$X \approx U_k \Sigma_k V_k^T$$

La décroissance des valeurs singulières indique que les premiers concepts capturent l'essentiel de la structure du corpus, comme illustré en Figure 2. La projection des documents dans l'espace latent est représentée en Figure 3, tandis que la projection des termes est présentée en Figure 4.

Contrairement à TF-IDF, la LSA exploite les co-occurrences globales. Elle projette les documents dans un espace latent de dimension K, permettant de capturer des proximités sémantiques indirectes.

7 Influence du paramètre K

Le paramètre K joue un rôle déterminant. Lorsque K est très faible (par exemple $K = 2$), la projection est fortement compressée. Après normalisation, de nombreux documents deviennent presque colinéaires, ce qui conduit à des similarités cosinus proches de 1. Ce phénomène correspond à une saturation de l'espace latent et traduit une perte de pouvoir discriminant. Cet effet est cohérent avec une projection documentaire concentrée, visible sur la structure de l'espace latent (Figure 3) et avec la concentration d'information dans les premières valeurs singulières (Figure 2).

Lorsque K augmente (par exemple $K = 20$), la représentation conserve davantage de variance. Les similarités maximales diminuent et le classement devient plus sélectif. Le choix de K correspond donc à un compromis entre abstraction sémantique et discrimination fine.

8 Interprétation des concepts latents

L'analyse des termes dominants associés à chaque dimension latente révèle des sous-thématiques cohérentes. Les Figures 5 à 9 présentent les quinze termes les plus représentatifs pour chaque concept, et la Figure 4 donne une vue globale de la structure termes-vers-concepts.

Certains concepts regroupent des termes liés aux tensions israélo-arabes, d'autres aux Balkans ou aux relations gréco-turques. Ces regroupements illustrent la capacité de la LSA à identifier des structures globales fondées sur les co-occurrences statistiques, au-delà des correspondances lexicales exactes.

9 Comparaison des requêtes

Les similarités TF-IDF observées sont comprises entre 0.24 et 0.34, ce qui est cohérent avec une représentation sparse en grande dimension, dont la structure est visible en Figure 1. Les similarités LSA peuvent atteindre des valeurs proches de 1 lorsque K est faible, mais deviennent plus discriminantes lorsque K augmente, ce qui est cohérent avec l'effet de compression décrit précédemment et avec la projection des documents en Figure 3.

TF-IDF privilégie la correspondance lexicale directe, tandis que la LSA capture des proximités sémantiques plus globales.

10 Discussion

Les résultats dépendent fortement des choix méthodologiques. Le prétraitement influence la structure du vocabulaire, les paramètres `min_df` et `max_df` modifient la distribution des poids, et le paramètre K contrôle le degré de compression sémantique. La figure des valeurs singulières (Figure 2) permet d'interpréter la part d'information capturée par les premiers concepts, et les figures de projection (Figures 4 et 3) fournissent un support visuel aux effets observés sur le classement.

L'étude étant menée sur un corpus homogène, les similarités globales sont naturellement élevées. Une extension multi-catégories permettrait d'évaluer plus finement la capacité de séparation inter-thématique.

11 Conclusion

Cette étude met en évidence la complémentarité entre TF-IDF et LSA. TF-IDF fournit une représentation lexicale précise mais très dimensionnelle et sparse. La LSA permet d'extraire des structures latentes interprétables en réduisant la dimension, au prix d'un paramétrage délicat.

Le choix des paramètres, notamment la dimension latente K, constitue un élément central du compromis entre abstraction sémantique et capacité discriminante.

Annexes

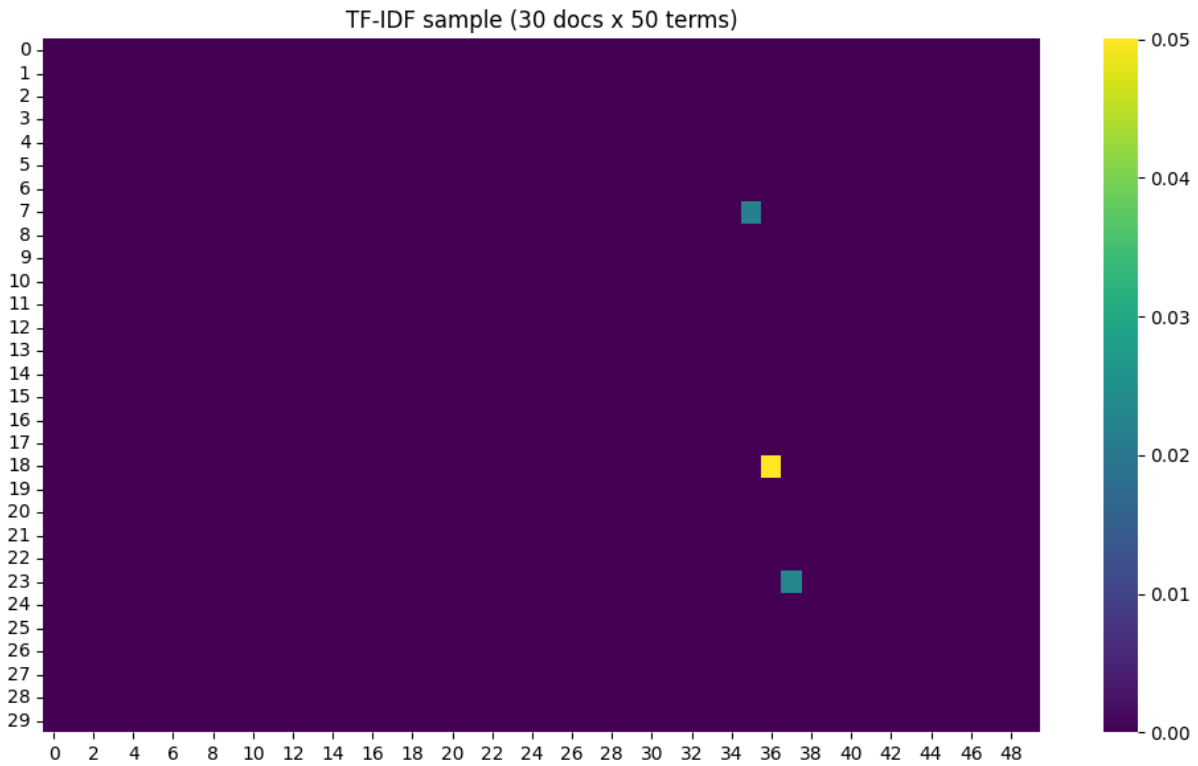

FIGURE 1 – Échantillon de la matrice TF-IDF (30 documents $\times$ 50 termes).

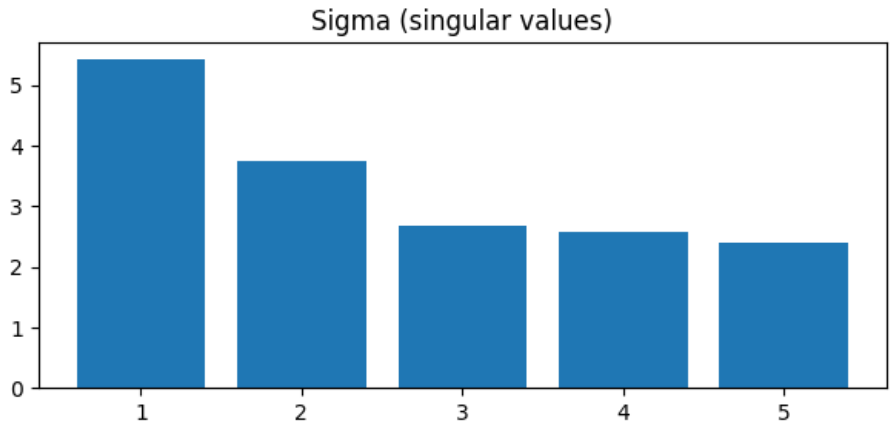

FIGURE 2 – Valeurs singulières issues de la décomposition SVD (exemple pour $K = 5$).

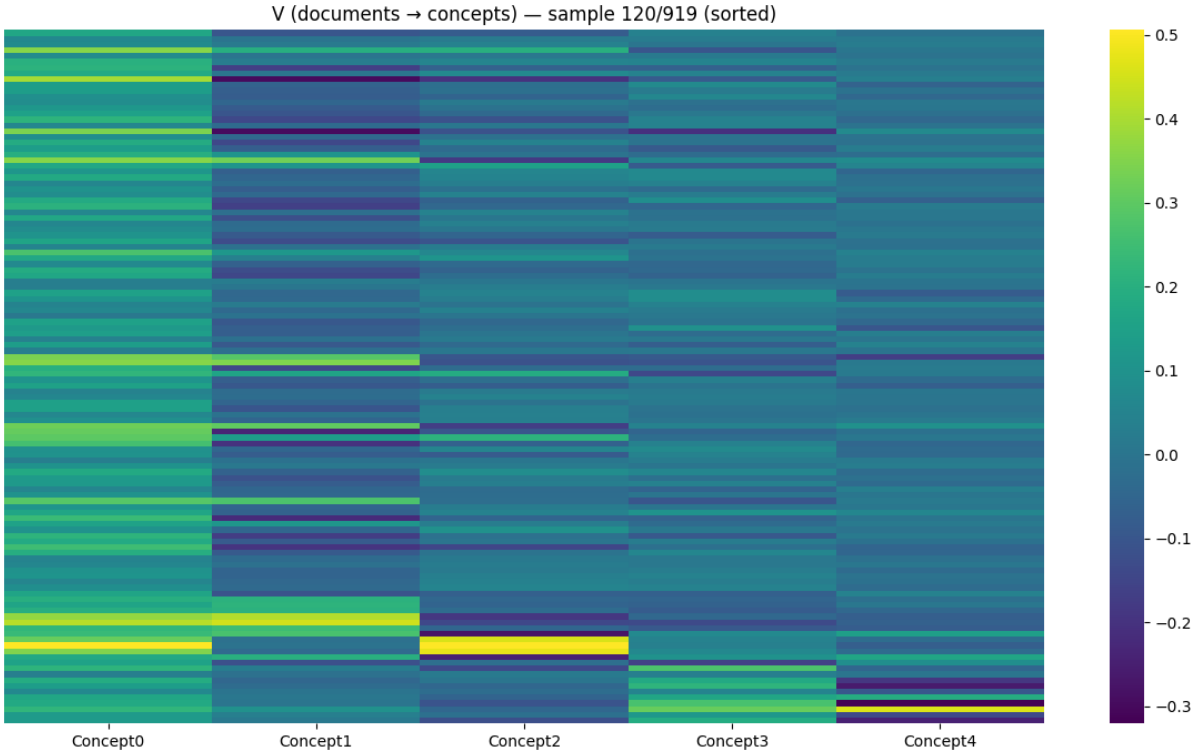

FIGURE 3 – Projection des documents dans l'espace latent (matrice V).

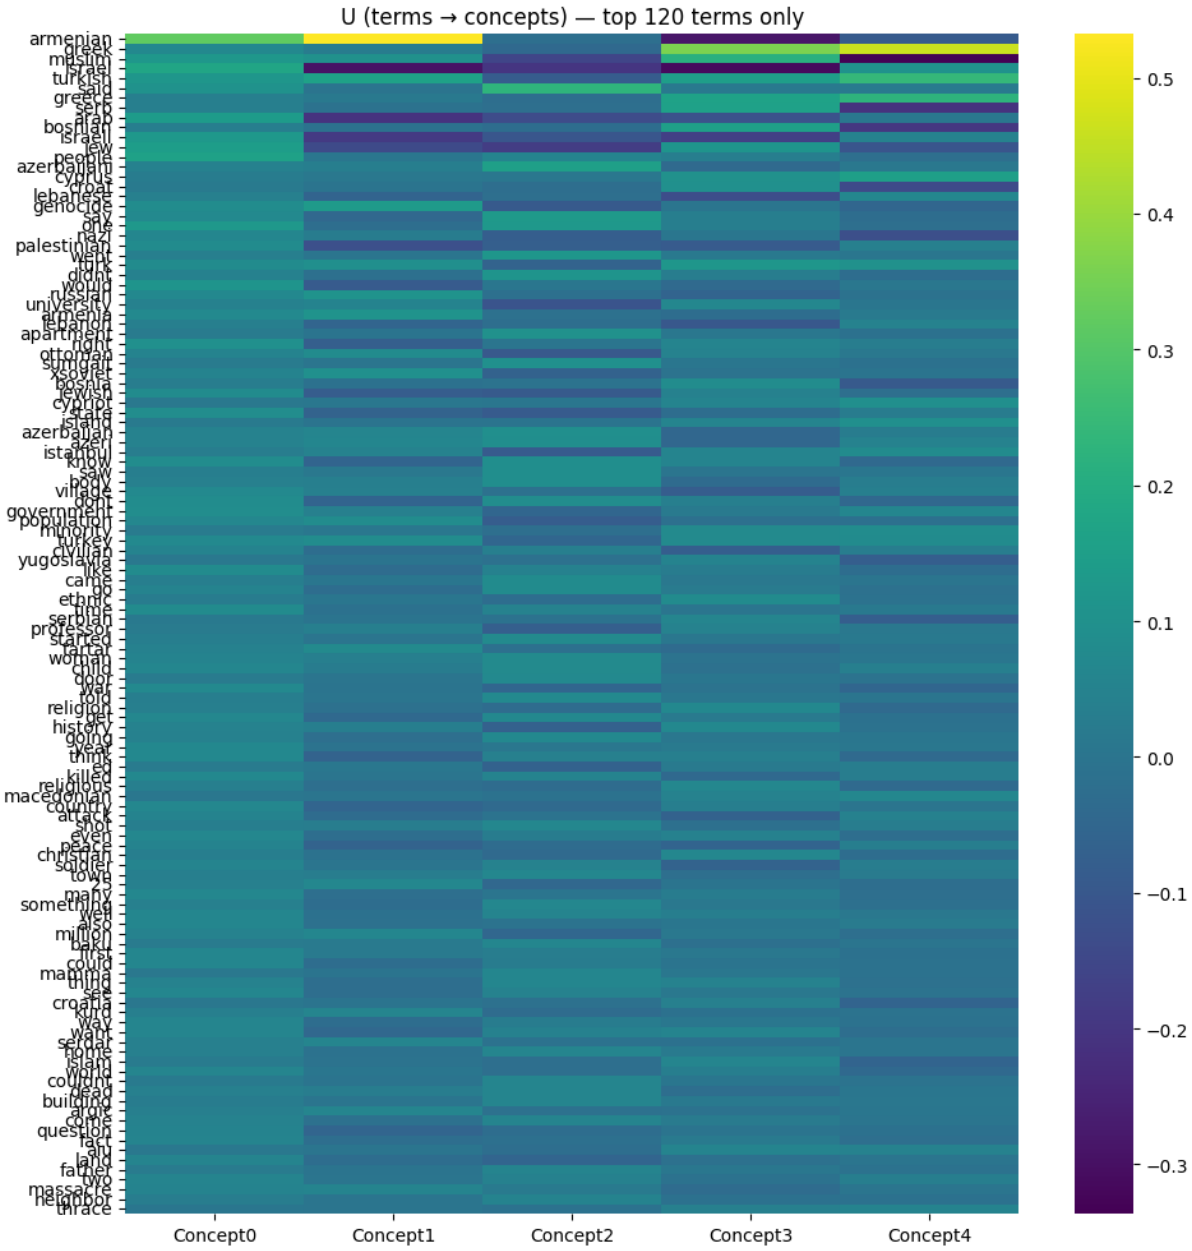

FIGURE 4 – Projection des termes dans l'espace latent (matrice U).

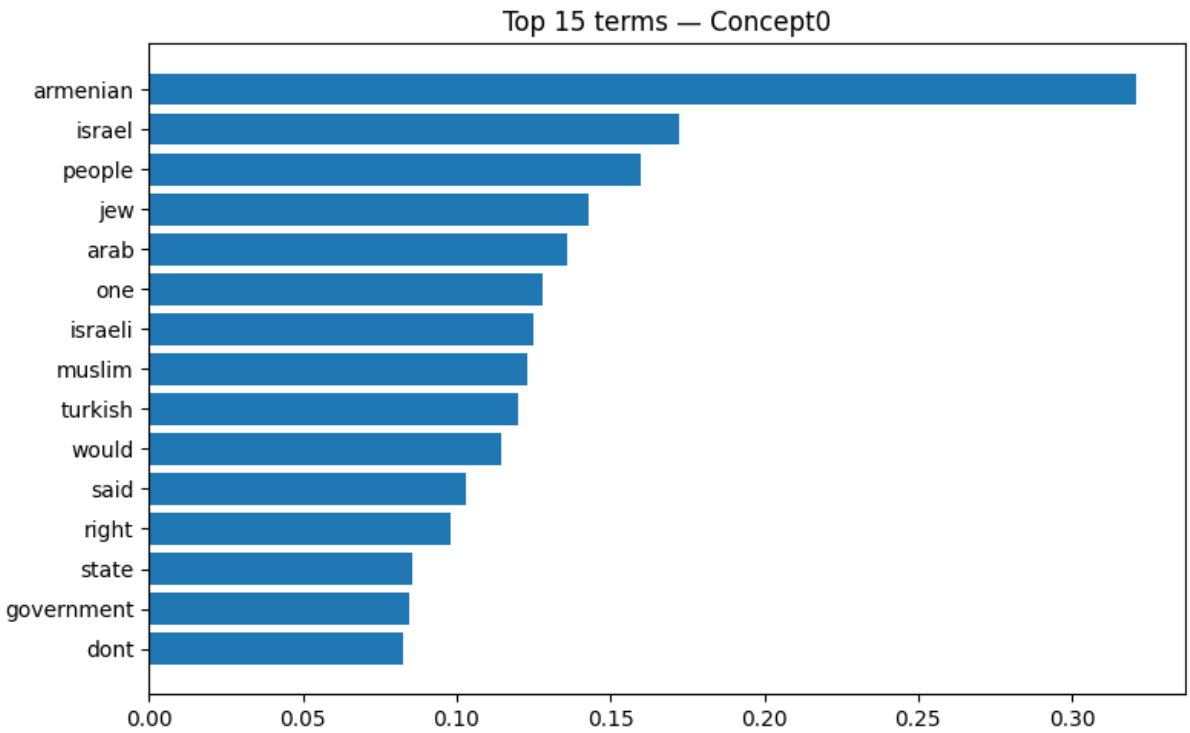

FIGURE 5 – Top 15 termes associés au Concept 0.

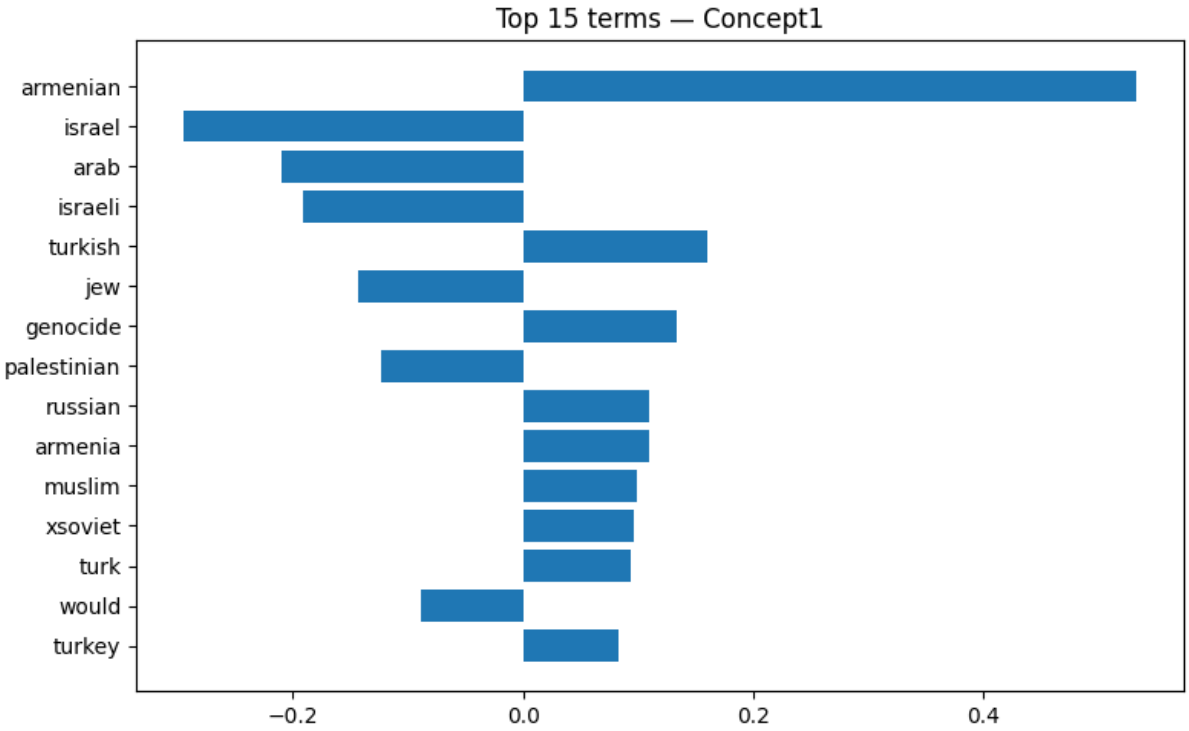

FIGURE 6 – Top 15 termes associés au Concept 1.

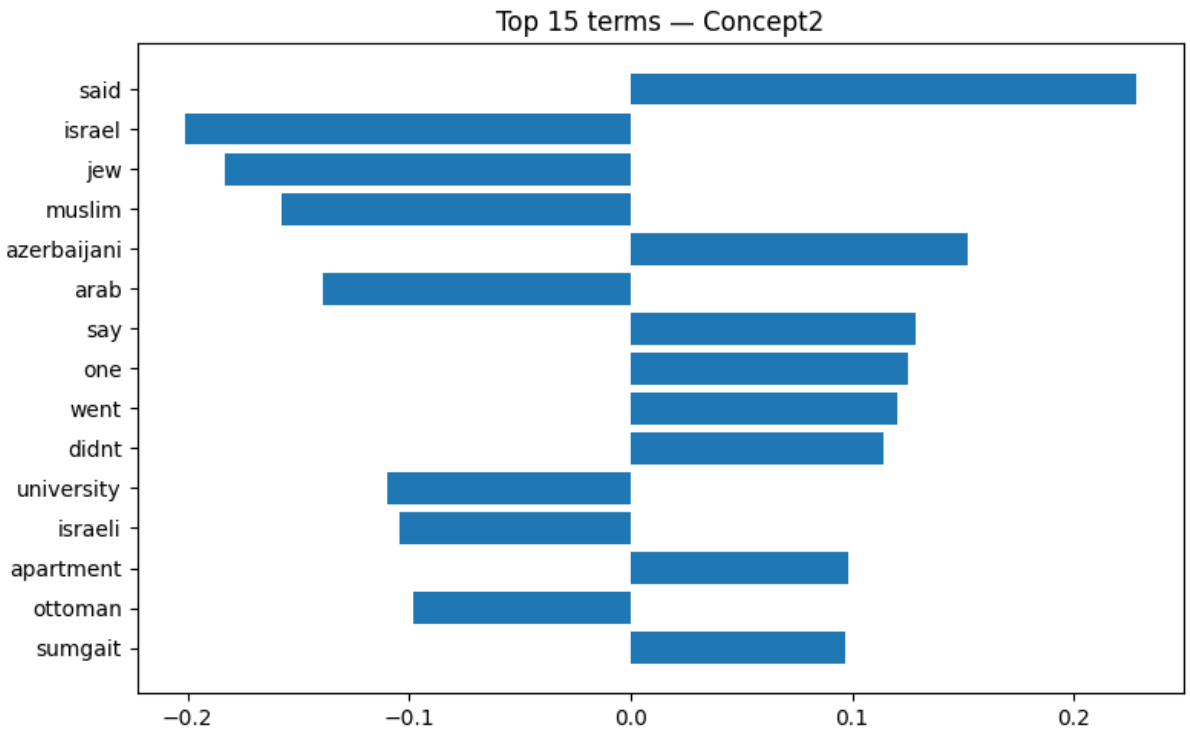

FIGURE 7 – Top 15 termes associés au Concept 2.

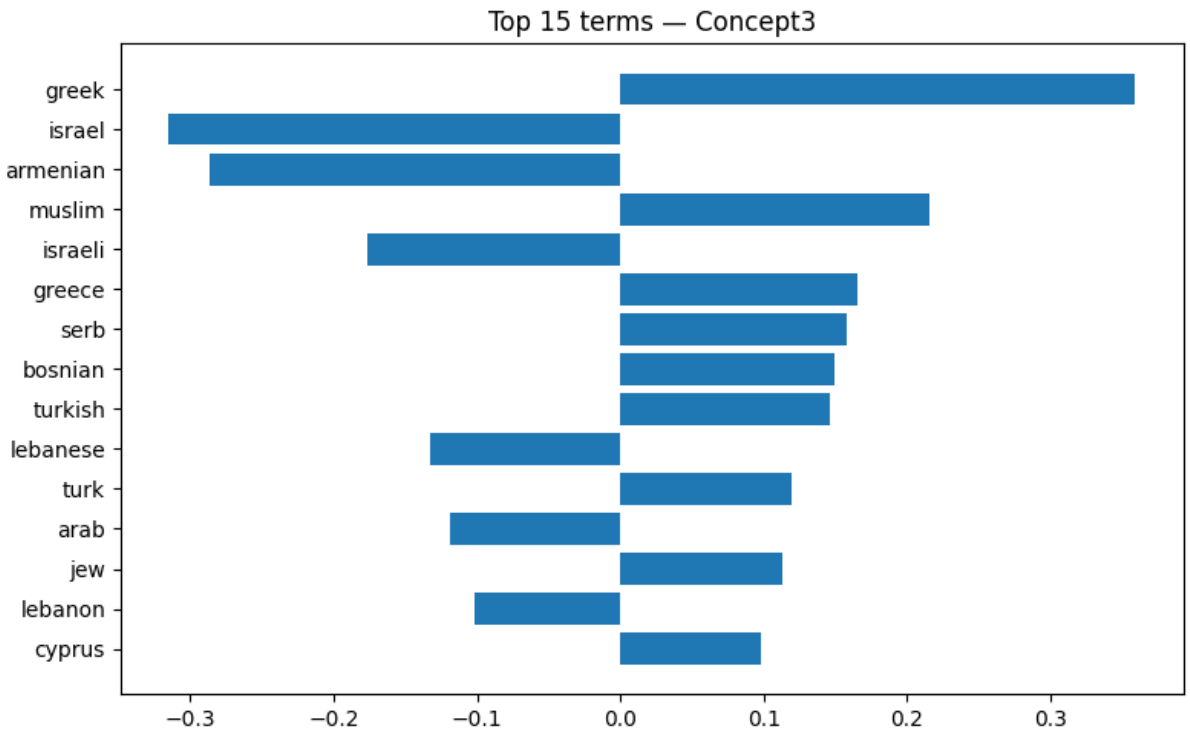

FIGURE 8 – Top 15 termes associés au Concept 3.

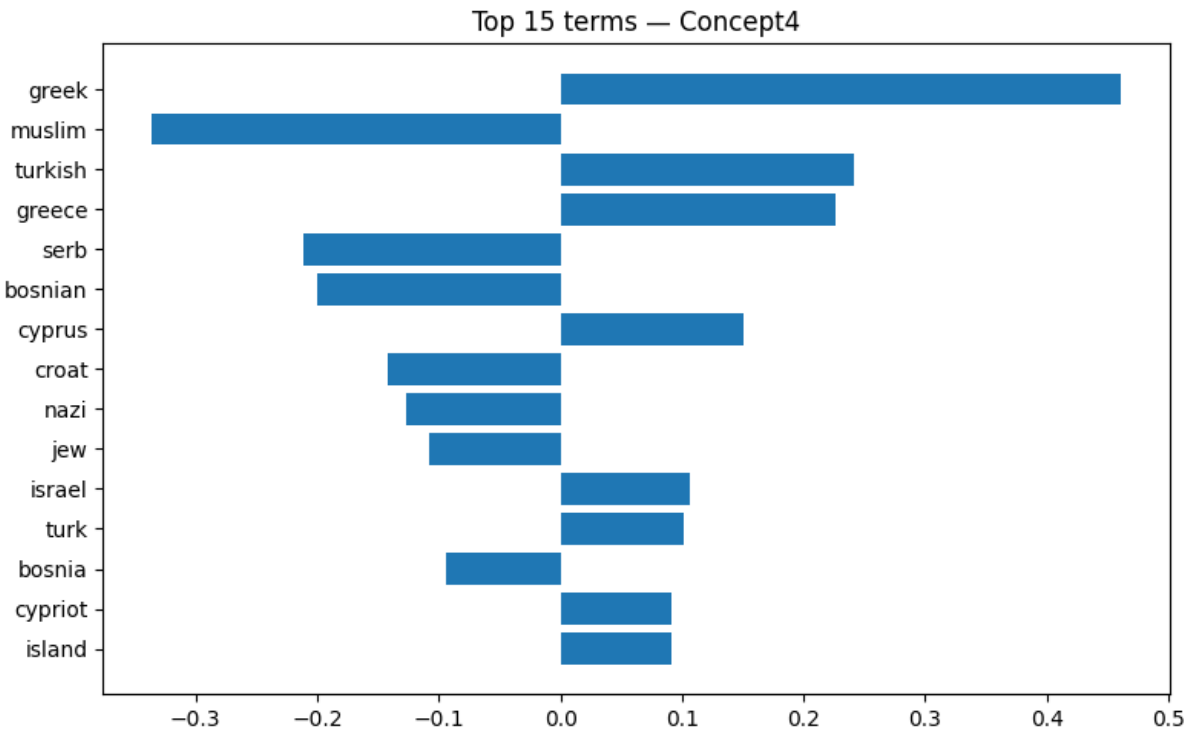

FIGURE 9 – Top 15 termes associés au Concept 4.