Université de Reims

Analyse comparative de TF-IDF et LSA

Étude sur le sous-corpus `talk.politics.mideast`

Auteur : Ismael Madou Gagi
Formation : Master Statistique pour l'évaluation et la prévision
Encadrant : Bart Lamiroy
lien du git: github.com/Ismael-madou/LSA

February 26, 2026

Contents

1 Introduction 2

2 Origine des données 2

3 Prétraitement des données 2

4 Analyse TF-IDF 4

5 Analyse Sémantique Latente (LSA) 5

6 Interprétation des concepts latents 6

7 Comparaison expérimentale des requêtes 7

8 Discussion 8

9 Conclusion 8

1 Introduction

La représentation vectorielle des documents constitue un pilier fondamental du traitement automatique des langues et de la recherche d'information. Deux approches historiques dominent ce domaine : la pondération TF-IDF et l'Analyse Sémantique Latente (LSA).

Ce travail vise à comparer expérimentalement ces deux méthodes sur un corpus politique réel. L'objectif est d'étudier leur structure mathématique, leur comportement sur des requêtes textuelles et leur capacité à capturer la sémantique sous-jacente des documents.

2 Origine des données

Le corpus utilisé provient de la base **20 Newsgroups**, téléchargée via la bibliothèque `sklearn.datasets.fetch_20newsgroups`. Cette base constitue un benchmark classique en apprentissage automatique.

La base complète contient environ 20 000 documents répartis en 20 sous-dossiers thématiques. Chaque sous-dossier correspond à une catégorie de discussion issue des forums Usenet.

Dans cette étude, nous avons volontairement restreint l'analyse à un seul sous-dossier :

`talk.politics.mideast`

Ce choix méthodologique permet d'étudier un corpus cohérent, centré sur les discussions politiques du Moyen-Orient, tout en conservant une richesse lexicale importante.

Après chargement et prétraitement, nous avons eu 919 documents et 18 066 termes distincts. Ainsi la matrice TF-IDF obtenue est donc :

$$X \in \mathbb{R}^{919 \times 18066}$$

3 Prétraitement des données

Avant la construction de la matrice TF-IDF, les documents ont subi une phase de prétraitement visant à normaliser et nettoyer le contenu textuel. Cette étape est essentielle afin de réduire le bruit lexical et d'améliorer la qualité de la représentation vectorielle.

Les opérations suivantes ont été appliquées :

Conversion en minuscules

Tous les documents ont été convertis en minuscules afin d'éviter de distinguer artificiellement des termes identiques différant uniquement par leur casse (par exemple « Israel » et « israel »). Cette opération a été réalisée en Python à l'aide de la méthode standard :

```
text = text.lower()
```

Cette normalisation réduit la taille effective du vocabulaire.

Suppression de la ponctuation

La ponctuation ne porte généralement pas d'information sémantique pertinente dans le cadre d'une modélisation sac-de-mots. Elle a été supprimée en utilisant la bibliothèque standard `string` de Python :

```
import string
tokens = ["".join([c for c in tok if c not in string.punctuation])
          for tok in tokens]
```

Cette opération empêche la création de tokens artificiels tels que « israel, » ou « conflict. ».

Suppression des stopwords

Les stopwords sont des mots très fréquents (par exemple « the », « and », « of ») qui apportent peu d'information discriminante. Leur suppression permet d'améliorer le signal informationnel des vecteurs TF-IDF.

Les stopwords ont été récupérés via la bibliothèque `NLTK` :

```
from nltk.corpus import stopwords
EN_STOPWORDS = set(stopwords.words("english"))

tokens = [tok for tok in tokens if tok not in EN_STOPWORDS]
```

Cette étape réduit fortement la dimension inutile du vocabulaire.

Lemmatisation

La lemmatisation consiste à ramener les mots à leur forme canonique (lemme). Par exemple :

- "running" → "run"

- "conflicts" → "conflict"
- "was" → "be"

Contrairement au stemming, la lemmatisation repose sur une analyse linguistique plus précise.

Nous avons utilisé la classe `WordNetLemmatizer` de NLTK :

```
from nltk.stem import WordNetLemmatizer
lemmatizer = WordNetLemmatizer()

tokens = [lemmatizer.lemmatize(tok) for tok in tokens]
```

La ressource linguistique WordNet a été téléchargée via :

```
nltk.download("wordnet")
```

Cette opération permet de regrouper les variantes morphologiques d'un même mot sous une forme unique, ce qui améliore la cohérence de la représentation vectorielle.

Impact du prétraitement

L'ensemble de ces transformations permet :

- de réduire la taille du vocabulaire
- d'augmenter la densité informationnelle des vecteurs
- de stabiliser la matrice TF-IDF
- d'améliorer la qualité de la décomposition SVD

Sans ces étapes, la matrice TF-IDF serait plus bruitée, plus dimensionnelle, et les concepts extraits par LSA seraient moins interprétables.

4 Analyse TF-IDF

La pondération TF-IDF (Term Frequency – Inverse Document Frequency) constitue une méthode classique de représentation vectorielle des documents dans un modèle sac-de-mots. Elle vise à mesurer l'importance d'un terme dans un document relativement à l'ensemble du corpus.

Mathématiquement, pour un terme t et un document d, la pondération TF-IDF s'écrit :

$$TFIDF(t,d) = TF(t,d) \times IDF(t)$$

où :

$$TF(t,d) = \frac{\text{nombre d'occurrences de } t \text{ dans } d}{\text{nombre total de termes dans } d}$$

et

$$IDF(t) = \log\left(\frac{N}{df(t)}\right)$$

avec N le nombre total de documents et $df(t)$ le nombre de documents contenant le terme t.

La composante TF mesure l'importance locale du terme dans le document, tandis que la composante IDF pénalise les termes trop fréquents dans le corpus global. Ainsi, les mots très courants comme "the" ou "and" reçoivent un poids faible, alors que des termes plus discriminants comme "palestinian" ou "jerusalem" obtiennent un poids plus élevé.

Dans notre étude, la matrice TF-IDF obtenue est de dimension :

$$X \in \mathbb{R}^{919 \times 18066}$$

Cela signifie que chaque document est représenté par un vecteur de 18 066 dimensions correspondant au vocabulaire total extrait après prétraitement.

Un échantillon de cette matrice est présenté en Figure 1. Cette visualisation (30 documents $\times$ 50 termes) met en évidence une propriété fondamentale des représentations sac-de-mots : la **forte sparsité**. La majorité des coefficients sont nuls, car chaque document ne contient qu'une fraction très limitée du vocabulaire global.

Cette forte dimensionnalité et cette sparsité ont plusieurs conséquences :

Premièrement, l'espace vectoriel est extrêmement étendu, ce qui rend l'interprétation globale difficile. Deuxièmement, les documents sont décrits uniquement par des occurrences lexicales exactes, sans prise en compte explicite des relations sémantiques entre termes.

Ces limitations motivent l'utilisation d'une méthode de réduction dimensionnelle comme l'Analyse Sémantique Latente (LSA), qui vise à extraire des structures latentes à partir de cette matrice initialement de grande dimension.

5 Analyse Sémantique Latente (LSA)

Afin de dépasser les limites de la représentation TF-IDF, notamment sa forte dimensionnalité et son absence de modélisation sémantique explicite, nous appliquons l'Analyse Sémantique Latente (LSA).

La LSA repose sur la décomposition en valeurs singulières (Singular Value Decomposition, SVD) de la matrice TF-IDF :

$$X = U\Sigma V^T$$

Dans la pratique, une approximation de rang réduit est utilisée :

$$X \approx U_k \Sigma_k V_k^T$$

où $k = 5$ représente le nombre de dimensions latentes conservées. Cette réduction permet de projeter les documents dans un espace de dimension plus faible, tout en conservant l'essentiel de l'information structurante du corpus.

La matrice Σ_k contient les valeurs singulières classées par ordre décroissant. Ces valeurs mesurent l'importance relative de chaque dimension latente. Comme illustré en Figure 2, on observe une décroissance progressive des valeurs singulières, ce qui signifie que les premiers concepts capturent la majorité de la variance de la matrice initiale. Cette propriété justifie le choix d'un espace latent de faible dimension.

La matrice U_k, représentée en Figure 4, projette les termes dans l'espace latent. Chaque colonne correspond à un concept, et chaque coefficient indique la contribution d'un terme à ce concept. L'analyse de ces coefficients permet d'interpréter sémantiquement les dimensions extraites.

La matrice V_k, illustrée en Figure 3, projette quant à elle les documents dans le même espace latent. Chaque document est ainsi représenté par un vecteur de dimension k, ce qui facilite le calcul de similarité et la mise en évidence de regroupements thématiques.

Contrairement à TF-IDF, qui repose uniquement sur des correspondances lexicales exactes, la LSA capture des relations latentes entre termes en exploitant les co-occurrences globales dans le corpus. Cette propriété permet d'atténuer les effets de synonymie et de bruit lexical, et d'obtenir une représentation plus structurée de l'espace documentaire.

6 Interprétation des concepts latents

L'analyse des termes les plus fortement corrélés à chaque dimension latente permet d'interpréter sémantiquement les axes extraits par la LSA. Les Figures 5 à 9 présentent les quinze termes les plus représentatifs pour chacun des cinq concepts.

Le Concept 0 (Figure 5) regroupe principalement des termes tels que *armenian*, *israel*, *jew*, *arab* et *muslim*. Cette concentration lexicale suggère un axe thématique centré sur les tensions ethno-religieuses et les conflits identitaires dans la région du Moyen-Orient. La co-occurrence fréquente de ces termes dans les mêmes documents explique leur regroupement dans une même dimension latente.

Le Concept 1 (Figure 6) met en évidence des termes comme *genocide*, *palestinian* et

russian. Ce regroupement peut être interprété comme un axe lié aux débats historiques et aux conflits géopolitiques impliquant des revendications territoriales ou mémorielles.

Le Concept 2 (Figure 7) semble davantage associé à des références historiques et institutionnelles, suggérant un axe plus académique ou contextuel.

Le Concept 3 (Figure 8) contient des termes tels que *greek*, *greece* et *bosnian*, ce qui reflète un sous-thème distinct relatif aux Balkans et aux tensions régionales en Europe du Sud-Est.

Enfin, le Concept 4 (Figure 9) regroupe des termes comme *cyprus* et *turkish*, indiquant un axe clairement centré sur les relations gréco-turques et la question chypriote.

Ces regroupements montrent que la LSA n'effectue pas un simple filtrage lexical, mais identifie des structures globales fondées sur les co-occurrences statistiques dans l'ensemble du corpus. Les dimensions latentes correspondent ainsi à des sous-thématiques géopolitiques cohérentes, ce qui confirme la capacité de la réduction dimensionnelle à révéler l'organisation interne d'un espace documentaire complexe.

7 Comparaison expérimentale des requêtes

Afin d'évaluer empiriquement les différences entre TF-IDF et LSA, trois requêtes ont été formulées en langue anglaise, cohérentes avec la langue du corpus : "israel palestinian conflict", "middle east peace process" et "religious tension jerusalem".

Pour la première requête, les similarités maximales obtenues avec TF-IDF sont de l'ordre de 0.33, tandis que les similarités LSA atteignent environ 0.99. Un comportement similaire est observé pour les deux autres requêtes : les scores TF-IDF restent compris entre 0.24 et 0.34, alors que les scores LSA sont systématiquement supérieurs à 0.98.

Cette différence importante d'amplitude s'explique par la nature géométrique des deux représentations. Dans le cas de TF-IDF, les vecteurs sont projetés dans un espace de très grande dimension (18 066 dimensions). Les similarités cosinus restent modérées car les vecteurs sont très dispersés et majoritairement creux.

En revanche, dans le cas de la LSA, les documents sont projetés dans un espace latent de dimension réduite ($k = 5$). Après normalisation, les vecteurs sont concentrés dans un sous-espace dense. Cette projection tend à rapprocher les documents partageant des structures thématiques similaires, ce qui conduit à des valeurs de similarité cosinus proches de 1.

Au-delà de la différence numérique, la distinction conceptuelle est essentielle. TF-IDF privilégie une correspondance lexicale stricte : les documents contenant explicitement les termes de la requête sont favorisés. En revanche, la LSA exploite les co-occurrences globales et capture des proximités sémantiques. Ainsi, un document peut obtenir un score élevé même s'il ne contient pas exactement tous les mots de la requête, dès lors qu'il appartient au même sous-espace thématique.

Ces observations confirment que la LSA introduit une forme d'abstraction sémantique absente du modèle TF-IDF classique.

8 Discussion

Au-delà des différences observées entre les scores de similarité, plusieurs éléments méthodologiques méritent d'être discutés.

Tout d'abord, les résultats obtenus dépendent fortement des choix effectués lors du prétraitement. La suppression des stopwords, la lemmatisation et la normalisation influencent directement la structure de la matrice TF-IDF. Une modification de ces paramètres pourrait entraîner une variation sensible des termes dominants et, par conséquent, des axes latents extraits par la SVD.

Ensuite, le choix du paramètre k constitue un critère précieux de l'expérimentation. La réduction à cinq dimensions permet d'obtenir une représentation synthétique et interprétable du corpus, mais elle implique nécessairement une perte d'information. Une valeur de k plus élevée aurait conservé davantage de variance, au prix d'une interprétation plus complexe. À l'inverse, une valeur trop faible aurait risqué d'écraser certaines sous-thématiques importantes.

Par ailleurs, l'amplitude élevée des similarités observées dans l'espace latent (proches de 1) suggère que la projection dans un espace de faible dimension concentre fortement les vecteurs documentaires. Cela facilite la détection de structures globales, mais peut également réduire la capacité discriminante fine entre documents très proches thématiquement.

Enfin, il convient de rappeler que l'ensemble de l'analyse repose sur un sous-corpus unique extrait de la base 20 Newsgroups. Les conclusions tirées ici sont donc valables dans le cadre d'un corpus thématiquement homogène. Une expérimentation sur l'ensemble des vingt catégories pourrait produire des comportements différents, notamment en raison d'une plus grande hétérogénéité lexicale.

Ces éléments montrent que les performances observées ne résultent pas uniquement du modèle choisi, mais également des décisions méthodologiques prises tout au long du pipeline expérimental.

9 Conclusion

Ce travail avait pour objectif d'examiner, sur un corpus politique cohérent issu de la base 20 Newsgroups, les différences de comportement entre une représentation vectorielle classique (TF-IDF) et une approche fondée sur la réduction dimensionnelle (LSA).

L'expérimentation menée sur le sous-corpus `talk.politics.mideast` a mis en évidence la capacité de la décomposition en valeurs singulières à structurer l'espace documentaire selon des axes latents interprétables. Les dimensions extraites ne correspondent

pas à des mots isolés, mais à des combinaisons statistiques reflétant des sous-thématiques géopolitiques présentes dans les discussions.

Au-delà des performances numériques observées lors des requêtes, l'intérêt principal de la LSA réside dans sa faculté à transformer un espace lexical très dimensionnel en une représentation synthétique et exploitable. Cette transformation facilite l'analyse globale du corpus et la mise en évidence de structures internes difficilement perceptibles dans l'espace initial.

Néanmoins, cette étude rappelle que les résultats obtenus dépendent étroitement des choix méthodologiques effectués : prétraitement, dimension retenue, normalisation. L'efficacité d'un modèle ne peut donc être évaluée indépendamment du cadre expérimental dans lequel il est appliqué.

En définitive, cette analyse confirme l'intérêt des méthodes de réduction dimensionnelle pour l'exploration thématique de corpus textuels structurés, tout en soulignant la nécessité d'un paramétrage réfléchi et adapté au contexte étudié.

Annexes

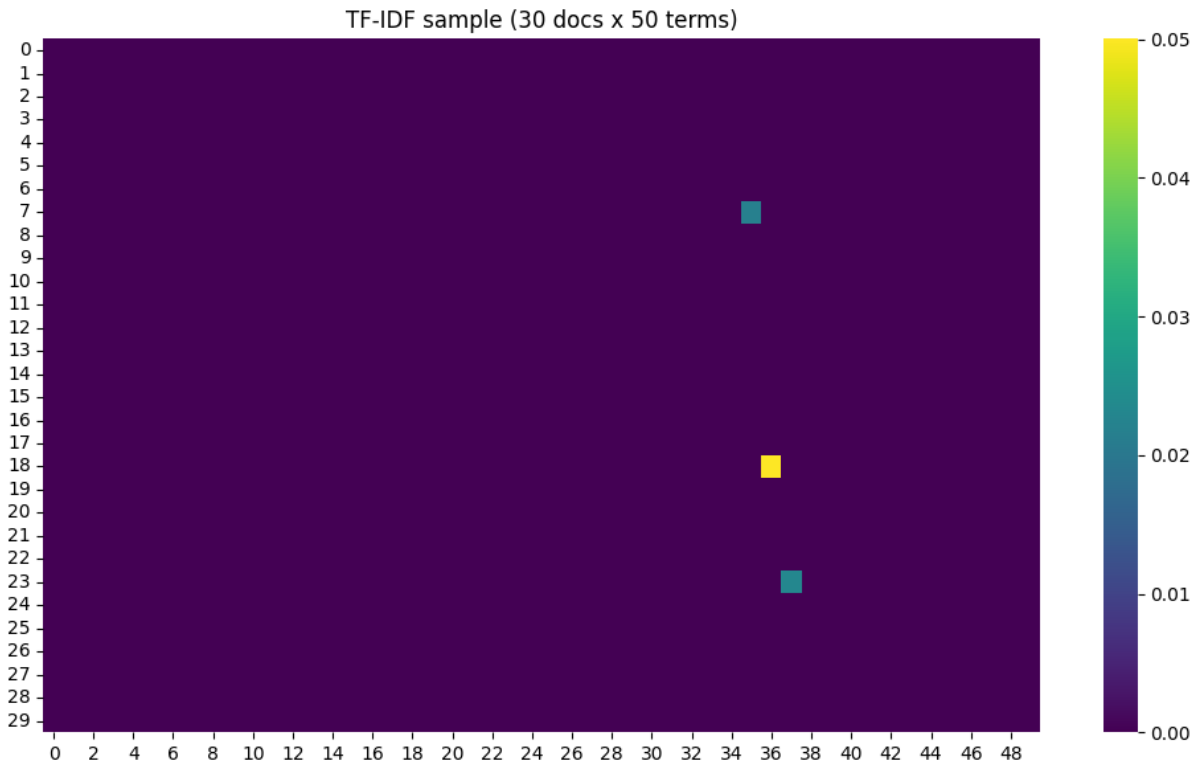

Figure 1: Échantillon de la matrice TF-IDF (30 documents × 50 termes).

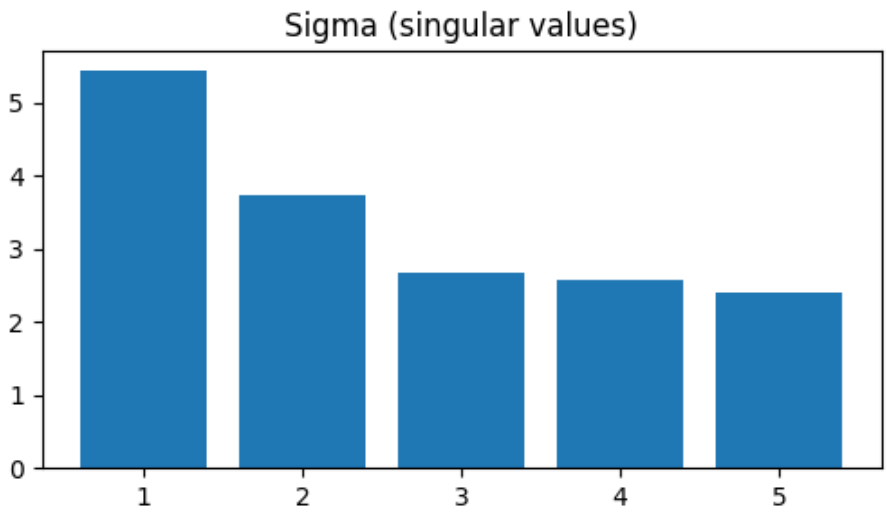

Figure 2: Valeurs singulières issues de la décomposition SVD pour k=5.

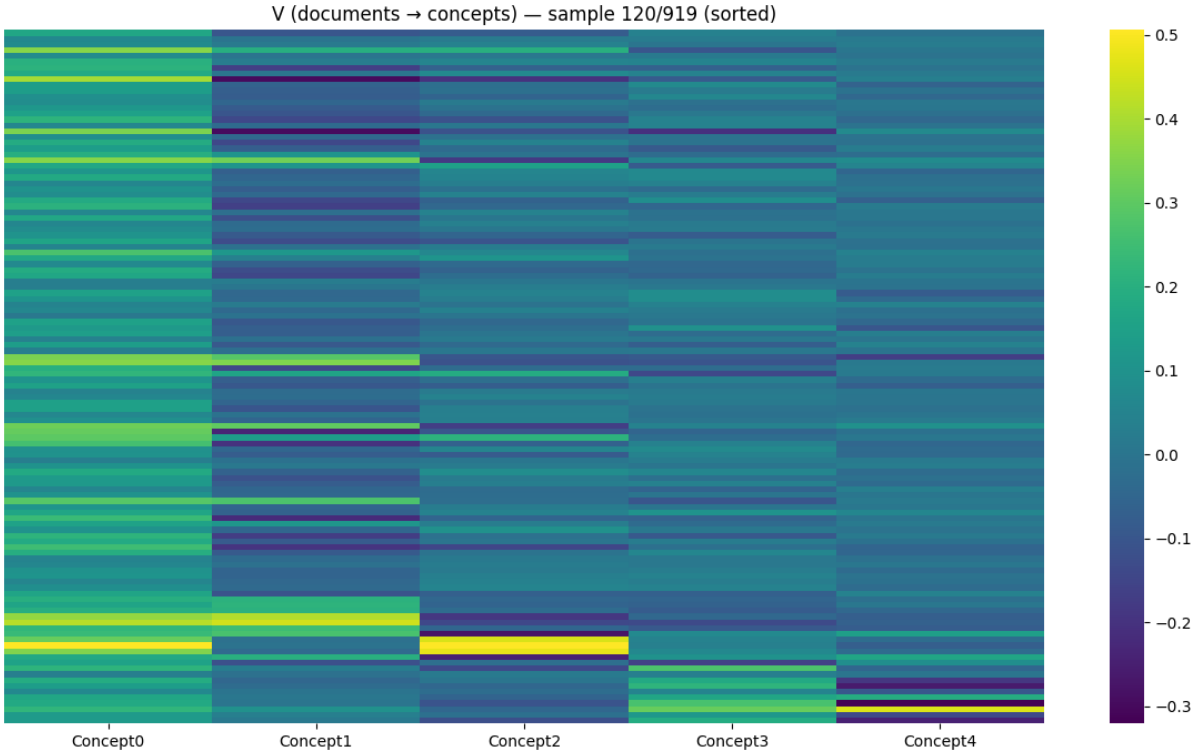

Figure 3: Projection des documents dans l'espace latent (matrice V).

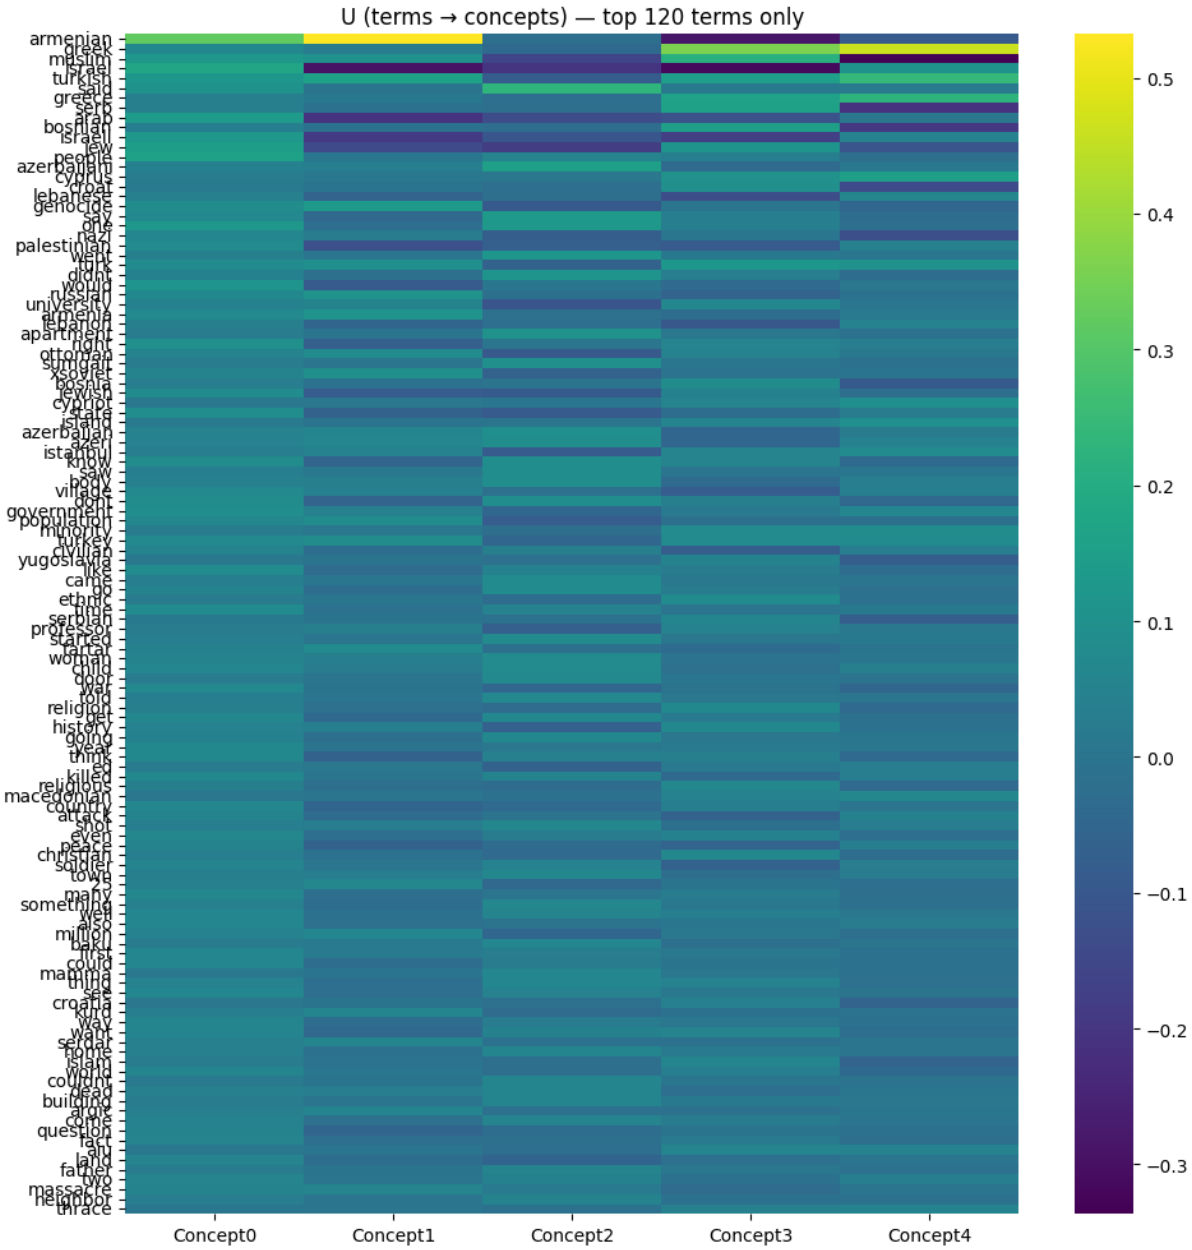

Figure 4: Projection des termes dans l'espace latent (matrice U).

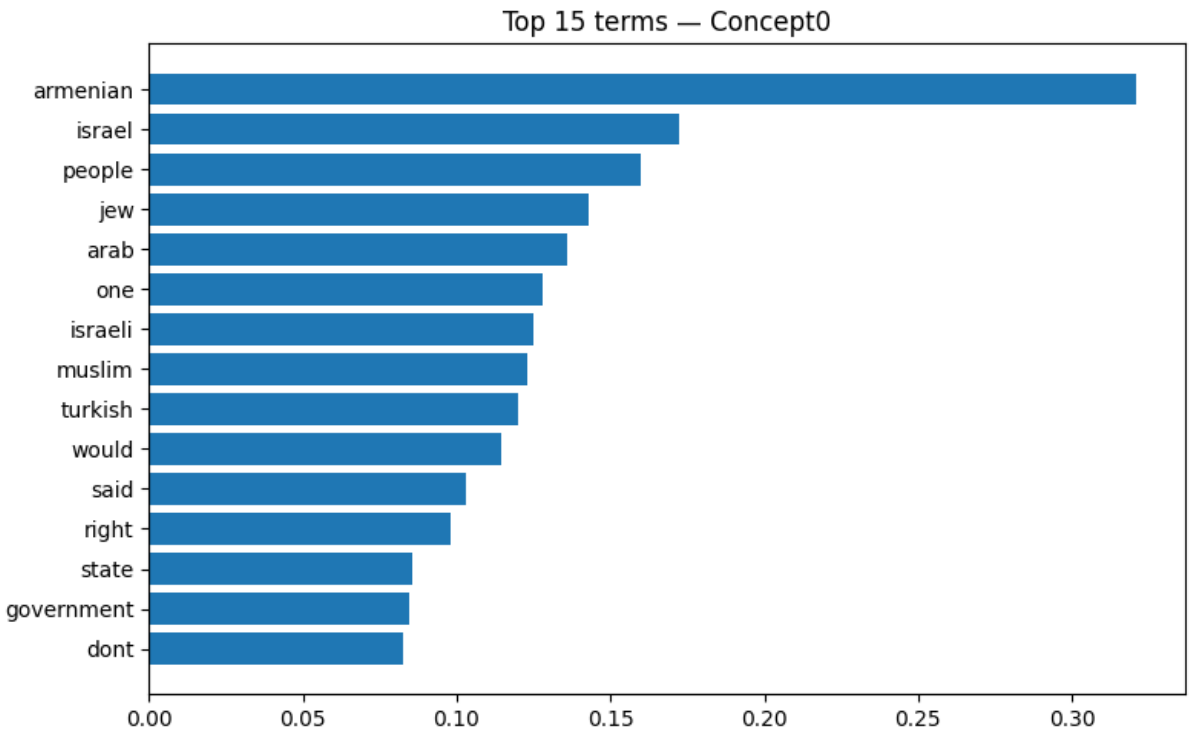

Figure 5: Top 15 termes associés au Concept 0.

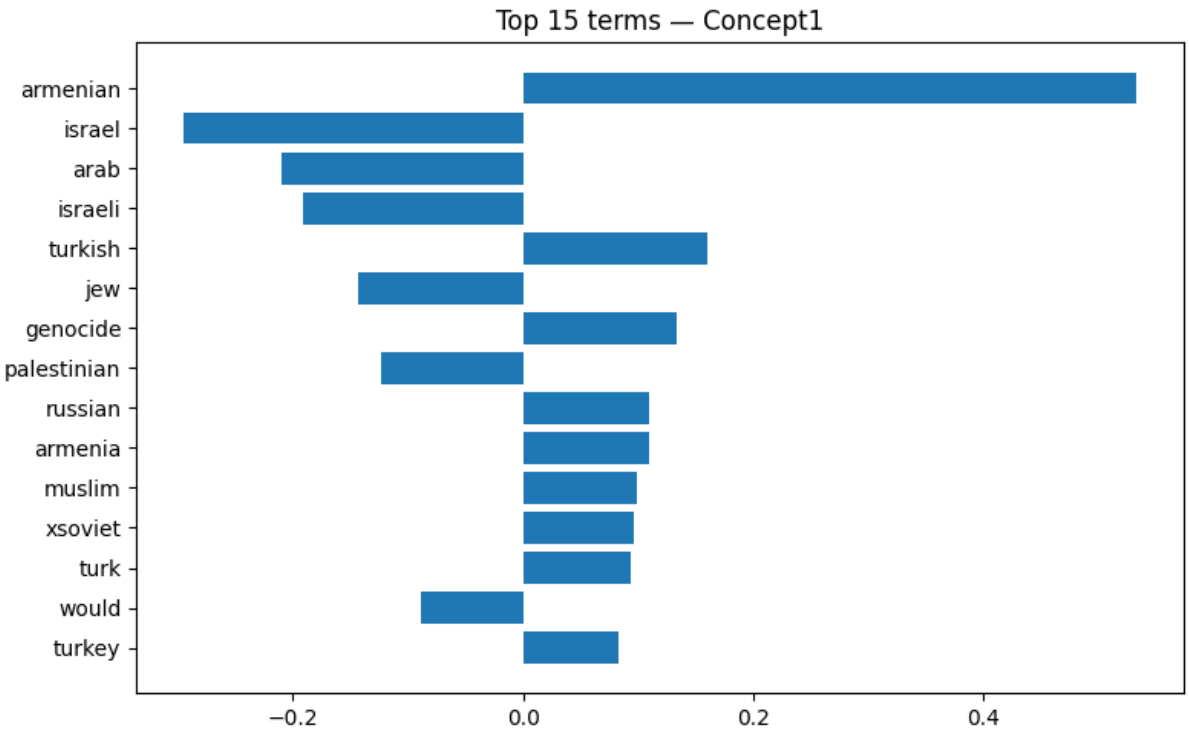

Figure 6: Top 15 termes associés au Concept 1.

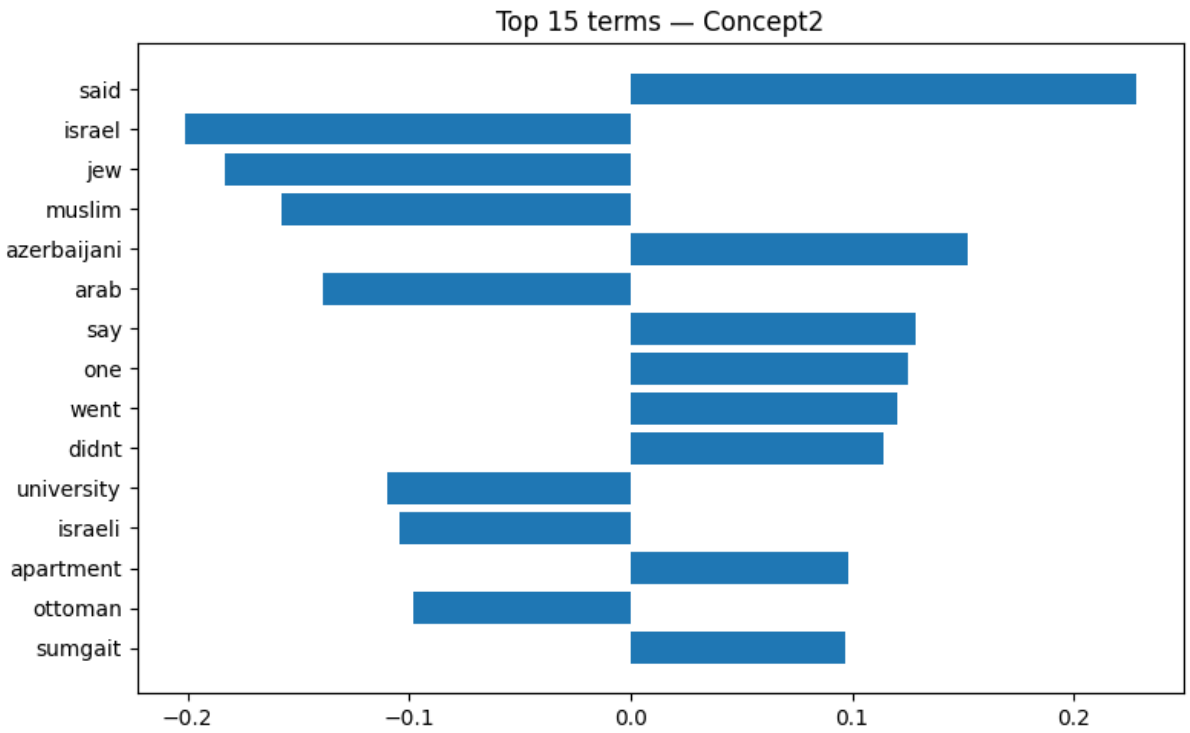

Figure 7: Top 15 termes associés au Concept 2.

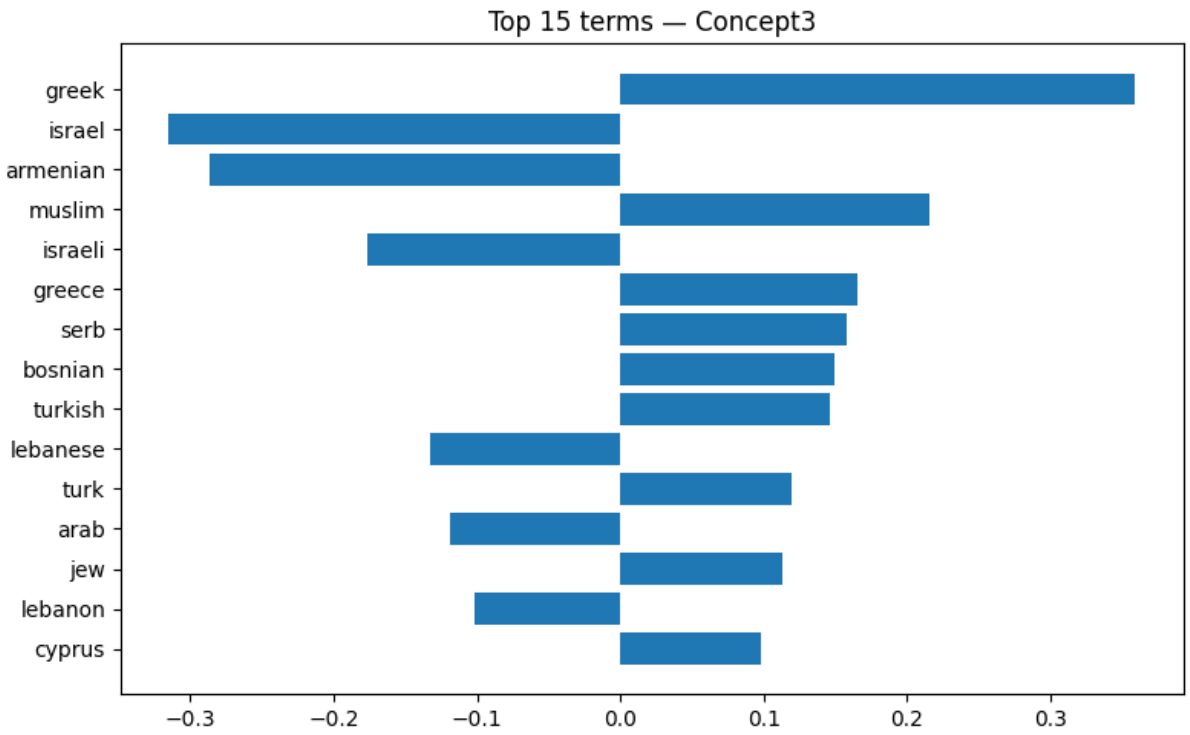

Figure 8: Top 15 termes associés au Concept 3.

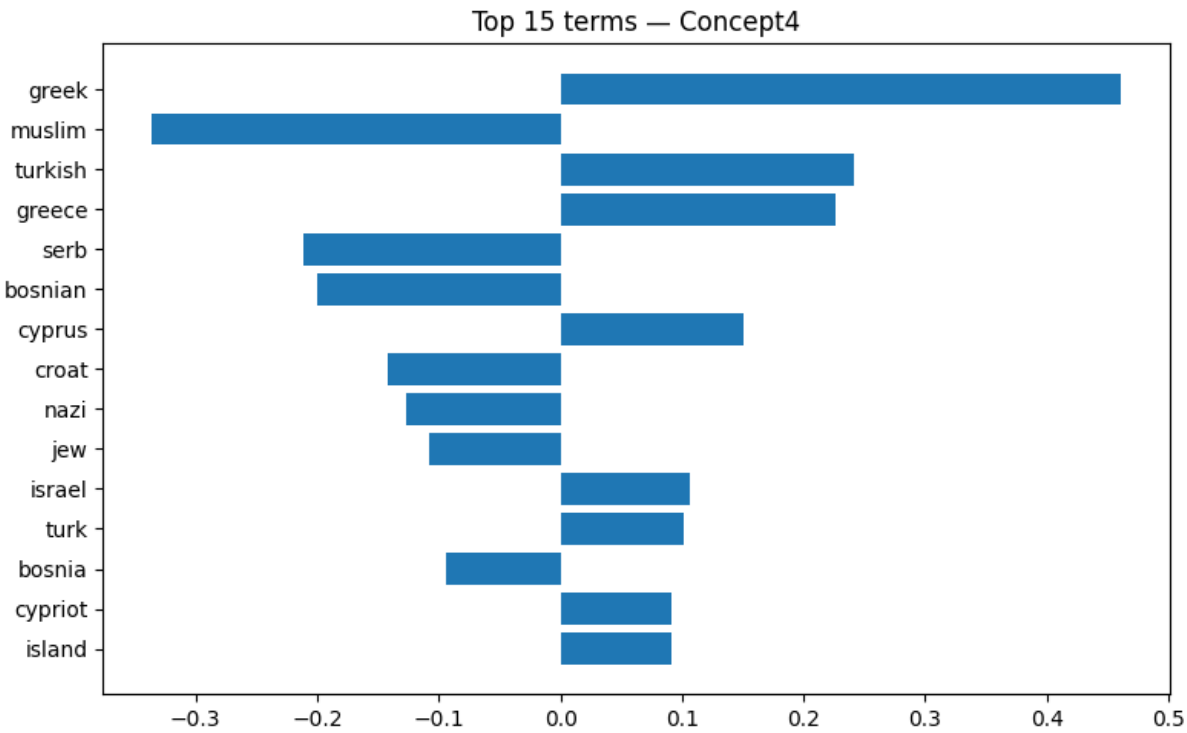

Figure 9: Top 15 termes associés au Concept 4.